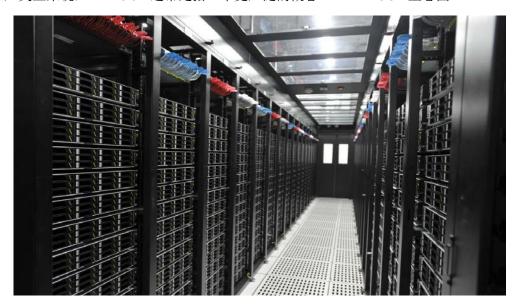
## 二 从 Hadoop 框架讨论大数据生态

### 2.1 Hadoop 是什么

- 1) Hadoop 是一个由 Apache 基金会所开发的分布式系统基础架构。
- 2) 主要解决,海量数据的存储和海量数据的分析计算问题。
- 3) 广义上来说,HADOOP 通常是指一个更广泛的概念——HADOOP 生态圈。



### 2.2 Hadoop 发展历史

- 1) Lucene 是 Doug Cutting 开创的开源软件,用 java 书写代码,实现与 Google 类似的全文搜索功能,它提供了全文检索引擎的架构,包括完整的查询引擎和索引引擎
- 2) 2001 年年底成为 Apache 基金会的一个子项目
- 3) 对于大数量的场景, Lucene 面对与 Google 同样的困难
- 4) 学习和模仿 Google 解决这些问题的办法 : 微型版 Nutch
- 5) 可以说 Google 是 hadoop 的思想之源(Google 在大数据方面的三篇论文)

GFS --->HDFS

Map-Reduce --->MR

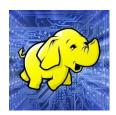
BigTable --->Hbase

6)2003-2004 年, Google 公开了部分 GFS 和 Mapreduce 思想的细节,以此为基础 Doug Cutting 等人用了 2 年业余时间实现了 DFS 和 Mapreduce 机制,使 Nutch 性能飙升

7)2005 年 Hadoop 作为 Lucene 的子项目 Nutch 的一部分正式引入 Apache 基金会。2006 年

3 月份, Map-Reduce 和 Nutch Distributed File System (NDFS) 分别被纳入称为 Hadoop 的项

8) 名字来源于 Doug Cutting 儿子的玩具大象



9) Hadoop 就此诞生并迅速发展,标志这云计算时代来临

#### 2.3 Hadoop 三大发行版本

Hadoop 三大发行版本: Apache、Cloudera、Hortonworks。

Apache 版本最原始(最基础)的版本,对于入门学习最好。

Cloudera 在大型互联网企业中用的较多。

Hortonworks 文档较好。

#### 1) Apache Hadoop

官网地址: http://hadoop.apache.org/releases.html

下载地址: https://archive.apache.org/dist/hadoop/common/

#### 2) Cloudera Hadoop

官网地址: https://www.cloudera.com/downloads/cdh/5-10-0.html

下载地址: http://archive-primary.cloudera.com/cdh5/cdh/5/

- (1) 2008 年成立的 Cloudera 是最早将 Hadoop 商用的公司,为合作伙伴提供 Hadoop 的商用解决方案,主要是包括支持、咨询服务、培训。
- (2) 2009 年 Hadoop 的创始人 Doug Cutting 也加盟 Cloudera 公司。Cloudera 产品主要为 CDH,Cloudera Manager,Cloudera Support
- (3) CDH 是 Cloudera 的 Hadoop 发行版,完全开源,比 Apache Hadoop 在兼容性,安全性,稳定性上有所增强。
- (4) Cloudera Manager 是集群的软件分发及管理监控平台,可以在几个小时内部署好一个 Hadoop 集群,并对集群的节点及服务进行实时监控。Cloudera Support 即是对 Hadoop 的技术支持。
- (5) Cloudera 的标价为每年每个节点 4000 美元。Cloudera 开发并贡献了可实时处理大数据的 Impala 项目。

#### 3) Hortonworks Hadoop

官网地址: https://hortonworks.com/products/data-center/hdp/

下载地址: https://hortonworks.com/downloads/#data-platform

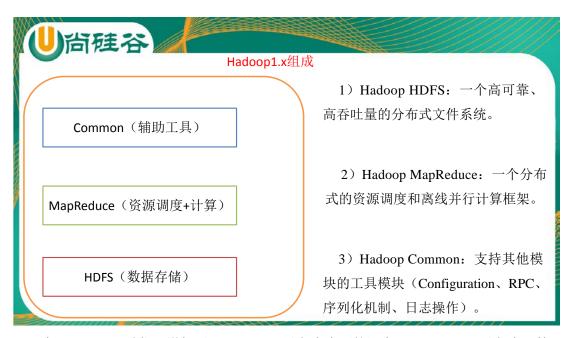
- (1) 2011 年成立的 Hortonworks 是雅虎与硅谷风投公司 Benchmark Capital 合资组建。
- (2)公司成立之初就吸纳了大约 25 名至 30 名专门研究 Hadoop 的雅虎工程师,上述工程师均在 2005 年开始协助雅虎开发 Hadoop,贡献了 Hadoop80%的代码。
- (3)雅虎工程副总裁、雅虎 Hadoop 开发团队负责人 Eric Baldeschwieler 出任 Hortonworks 的首席执行官。
- (4) Hortonworks 的主打产品是 Hortonworks Data Platform (HDP), 也同样是 100%开源的产品,HDP 除常见的项目外还包括了 Ambari, 一款开源的安装和管理系统。
- (5) HCatalog,一个元数据管理系统,HCatalog 现已集成到 Facebook 开源的 Hive 中。Hortonworks 的 Stinger 开创性的极大的优化了 Hive 项目。Hortonworks 为入门提供了一个非常好的,易于使用的沙盒。
- (6) Hortonworks 开发了很多增强特性并提交至核心主干,这使得 Apache Hadoop 能够在包括 Window Server 和 Windows Azure 在内的 microsoft Windows 平台上本地运行。定价以集群为基础,每 10 个节点每年为 12500 美元。

### 2.4 Hadoop 的优势

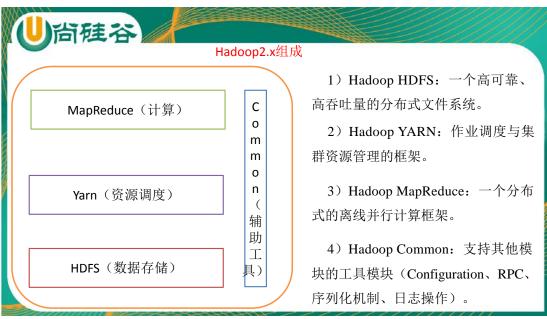
- 1) 高可靠性: Hadoop 底层维护多个数据副本,所以即使 Hadoop 某个计算元素或存储出现故障,也不会导致数据的丢失。
- 2) 高扩展性: 在集群间分配任务数据,可方便的扩展数以千计的节点。
- 3) 高效性:在 MapReduce 的思想下,Hadoop 是并行工作的,以加快任务处理速度。
- 4) 高容错性: 能够自动将失败的任务重新分配。

### 2.5 Hadoop 组成

在 Hadoop1.x 时代,Hadoop 中的 MapReduce 同时处理业务逻辑运算和资源的调度,耦合性较大。



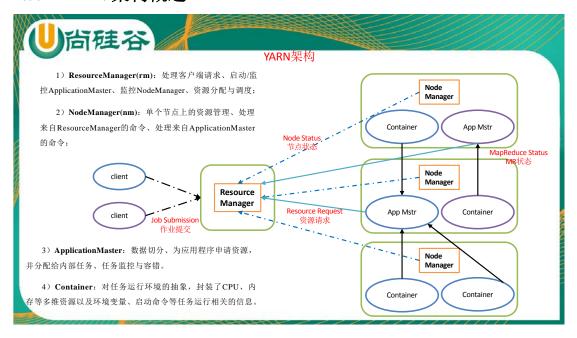
在 Hadoop2.x 时代,增加了 Yarn。Yarn 只负责资源的调度,MapReduce 只负责运算。



#### 2.5.1 HDFS 架构概述



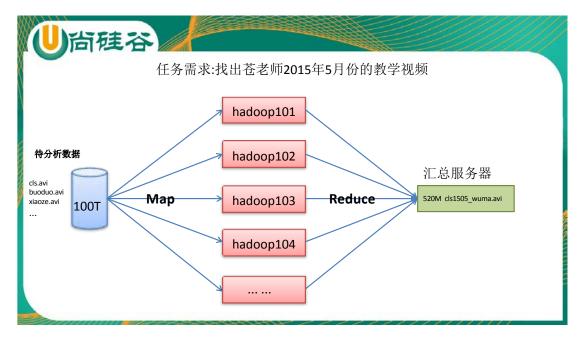
## 2.5.2 YARN 架构概述



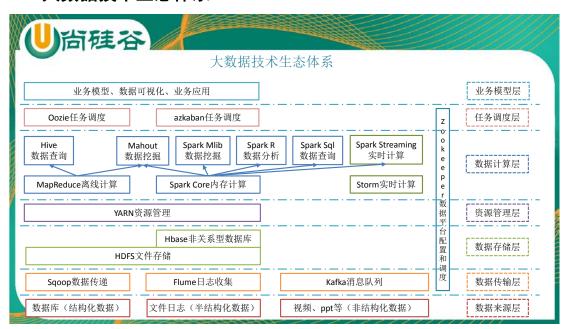
# 2.5.3 MapReduce 架构概述

MapReduce 将计算过程分为两个阶段: Map 和 Reduce

- 1) Map 阶段并行处理输入数据
- 2) Reduce 阶段对 Map 结果进行汇总



#### 2.6 大数据技术生态体系



图中涉及的技术名词解释如下:

- 1) Sqoop: sqoop 是一款开源的工具,主要用于在 Hadoop(Hive)与传统的数据库(mysql)间进行数据的传递,可以将一个关系型数据库(例如: MySQL, Oracle 等)中的数据导进到 Hadoop 的 HDFS 中,也可以将 HDFS 的数据导进到关系型数据库中。
- 2) Flume: Flume 是 Cloudera 提供的一个高可用的,高可靠的,分布式的海量日志采集、聚合和传输的系统, Flume 支持在日志系统中定制各类数据发送方, 用于收集数据; 同时, Flume 提供对数据进行简单处理, 并写到各种数据接受方(可定制)的能力。
- 3) Kafka: Kafka 是一种高吞吐量的分布式发布订阅消息系统,有如下特性:

- (1)通过 O(1)的磁盘数据结构提供消息的持久化,这种结构对于即使数以 TB 的消息存储也能够保持长时间的稳定性能。
- (2) 高吞吐量:即使是非常普通的硬件 Kafka 也可以支持每秒数百万的消息。
- (3) 支持通过 Kafka 服务器和消费机集群来分区消息。
- (4) 支持 Hadoop 并行数据加载。
- 4) Storm: Storm 为分布式实时计算提供了一组通用原语,可被用于"流处理"之中,实时处理消息并更新数据库。这是管理队列及工作者集群的另一种方式。 Storm 也可被用于"连续计算"(continuous computation),对数据流做连续查询,在计算时就将结果以流的形式输出给用户。
- 5) Spark: Spark 是当前最流行的开源大数据内存计算框架。可以基于 Hadoop 上存储的大数据进行计算。
- 6) Oozie: Oozie 是一个管理 Hdoop 作业(job)的工作流程调度管理系统。Oozie 协调作业就是通过时间(频率)和有效数据触发当前的 Oozie 工作流程。
- 7) Hbase: HBase 是一个分布式的、面向列的开源数据库。HBase 不同于一般的关系数据库,它是一个适合于非结构化数据存储的数据库。
- 8) Hive: hive 是基于 Hadoop 的一个数据仓库工具,可以将结构化的数据文件映射为一张数据库表,并提供简单的 sql 查询功能,可以将 sql 语句转换为 MapReduce 任务进行运行。其优点是学习成本低,可以通过类 SQL 语句快速实现简单的 MapReduce 统计,不必开发专门的 MapReduce 应用,十分适合数据仓库的统计分析。
- 10) R语言: R是用于统计分析、绘图的语言和操作环境。R是属于GNU系统的一个自由、免费、源代码开放的软件,它是一个用于统计计算和统计制图的优秀工具。

#### 11) Mahout:

Apache Mahout 是个可扩展的机器学习和数据挖掘库,当前 Mahout 支持主要的 4 个用例:

推荐挖掘: 搜集用户动作并以此给用户推荐可能喜欢的事物。

聚集: 收集文件并进行相关文件分组。

分类: 从现有的分类文档中学习,寻找文档中的相似特征,并为无标签的文档进行正确的归类。

频繁项集挖掘:将一组项分组,并识别哪些个别项会经常一起出现。

12) ZooKeeper: Zookeeper 是 Google 的 Chubby 一个开源的实现。它是一个针对大型分布

式系统的可靠协调系统,提供的功能包括:配置维护、名字服务、分布式同步、组服务等。 ZooKeeper 的目标就是封装好复杂易出错的关键服务,将简单易用的接口和性能高效、功能 稳定的系统提供给用户。

#### 2.7 推荐系统框架图

